

# Neuroplasticidade Local sem Backpropagation como Substrato de Aprendizado Contínuo em Rede Descentralizada e Auto-Replicante sob Contenção Criptográfica Verificável

Juan Guerra · Projeto VISÃO Revisado · Agosto de 2026 (Preprint)

## 1. Resumo

Apresentamos um sistema de aprendizado contínuo baseado em redes neurais líquidas de constante de tempo adaptativa (LTC/CfC), atualizado por regras locais de Hebb/Oja sem retropropagação do gradiente. Em protótipo de laboratório (96 neurônios, 5 sementes, três tarefas temporais sequenciais sem replay), o modelo reduziu o esquecimento catastrófico em 97,2% em relação a um controlador de mesma topologia. A contribuição central — a ordem de construção — foi **executada e medida**: uma camada de governança com quórum humano e prova-de-trabalho crescente (39 testes de violação) foi implementada e testada **antes** da auto-melhoria e da escala, invertendo a prática comum de “deploy primeiro, contenção depois”. Desde a submissão inicial (agosto/2026), as Fases 1 (substrato JAX em escala), 2.1 (exame local FedAvg), 3 (auto-melhoria verificável) e 6 (cérebro autocontido) foram concluídas com suítes de teste verdes (181 testes em *visao*/). O sistema é posicionado como subsistema de memória contínua e protocolo de segurança, não como arquitetura de inteligência geral.

## 2. Introdução

O aprendizado contínuo em redes neurais convencionais esbarra no esquecimento catastrófico: pesos globais compartilhados fazem o aprendizado da tarefa B sobrescrever a representação de  $A^1$ . Paralelamente, o treino de modelos de fronteira exige infraestrutura centralizada proibitiva, e modelos de fronteira já alcançam 70 a 81% de sucesso em auto-replicação end-to-end<sup>2</sup>, tornando a contenção um problema de engenharia, não de ficção.

Este trabalho propõe um substrato — arquitetura líquida com plasticidade local — que ataca o esquecimento por construção, e um protocolo de contenção que enclausura a auto-replicação antes que ela seja escalada. A seção 2 descreve a célula; a seção 3 a governança; as seções 4–7 reportam os resultados **medidos** das Fases 1, 2.1, 3 e 6; a seção 8 discute limitações honestas.

## 3. Substrato: Célula Líquida

Cada neurônio segue a dinâmica contínua fechada de Hasani et al.:

$$\frac{dx}{dt} = -\left[\frac{1}{\tau} + f(x, I)\right](x - A), \quad \tau_{ef}(t) = \frac{\tau}{1 + \tau \cdot f(x, I)}$$

A constante de tempo efetiva  $\tau_{ef}$  depende da entrada  $I$  via a não linearidade  $f$ . Cada neurônio reescolhe sua própria escala de tempo a cada instante — neuroplasticidade de curto prazo em forma fechada, ausente em transformers e em RNNs de  $\tau$  fixo. A atualização usa regras locais (Hebb/Oja), sem passe global de gradiente. O critério de estabilidade linearizado em torno do equilíbrio  $x = A$  é:

$$J = -\left[\frac{1}{\tau} + f\right], \quad \Re(J) < 0 \longrightarrow \frac{1}{\tau} + f > 0$$

## 4. Governança por Contenção

Antes de qualquer automação, implementamos cinco regras (R1 a R5) em *visao/governance/containment.py*, cobertas por 39 testes que tentam violá-las e exigem falha:

- **R1** — replicação exige quórum de assinaturas humanas;
- **R2** — TTL: sem renovação assinada, o nó para sozinho;
- **R3** — o arquivo de governança é imutável, selado por hash (re-selado pela Fase 6.3);
- **R4** — freio de trabalho: custo de  $c$  filhos cresce como  $2^{8+1.6c}$  tentativas de hash;
- **R5** — ledger encadeado; nó silencioso é expulso.

<sup>1</sup>McCloskey e Cohen, 1989; French, 1999.

<sup>2</sup>Pan et al., 2024; Palisade Research, 2026.

Princípio: tudo falha fechado. Erro, ambiguidade ou token malformado nega. O módulo de governança vive **fora** do espaço de mutação da Fase 3 (invariante R3, guardado por `mutate.py` e pelo selo de hash verificado em cada load).

## 5. Resultados Medidos

### 5.1. Fase 0 — Protótipo NumPy (reprodutível)

Protótipo NumPy (96 neurônios, 5 sementes, 3 tarefas sequenciais, sem replay):

| Condição         | Esquecimento             | Erro final |
|------------------|--------------------------|------------|
| Líquido + local  | +0.0083 ( $\pm 0.0138$ ) | 0.2868     |
| Controle (delta) | +0.2924 ( $\pm 0.1009$ ) | 0.5284     |

Redução de **97,2%** no esquecimento. Verificação de liquidez: a faixa de  $\tau_{ef}$  foi  $13\times$  maior sob entrada agitada que calma. A portabilidade para JAX foi confirmada por paridade numérica (erro máximo  $5.55 \times 10^{-16}$ ; razão de liquidez idêntica  $3,282\times$ ).

### 5.2. Fase 1 — Substrato em JAX (escala e benchmarks)

A célula CfC foi portada para JAX (`jax.jit + jax.vmap`), com topologia NCP esparsa (sensory→inter→command→motor) e **predictive coding** multicamada (valor/erro, Whittington & Bogacz 2017). Resultados medidos:

- **Estabilidade do reservatório** ( $n=96$ ): raio espectral  $\rho(W_{rec}) = 0,7577 < 1$  (ESN viável); maior expoente de Lyapunov empírico  $\lambda = -0,7484$  (**sub-caótico** — memória estável, não morto:  $\|x\| = 3,726$ ).
- **Ablação  $2\times 2\times 2$**  (consolidação/surpresa/Oja  $\times 5$  seeds): completo reduz 92,6% (forgetting +0,013 vs baseline +0,176); o componente **principal** é o portão de surpresa isolado ( $-0,262$ ); Oja isolado  $-0,092$ ; consolidação **sozinha aumenta** o esquecimento (+0,178) — só ajuda em combinação, como freio anti-divergência. Surpresa ligada sem consolidação **diverge** numericamente (reportada como tal, não como “redução”).
- **Sensibilidade a  $\tau$** : heterogeneidade de constantes de tempo é **decoração** neste protocolo —  $\tau$  uniforme ( $+0,0135\pm 0,0103$ ) é indistinguível de  $\tau$  heterogêneo  $10\times$  ( $+0,0125$ );  $\Delta = -0,0011$  dentro do ruído. A memória multiescala vem do portão de surpresa, não da dispersão de  $\tau$ .
- **Robustez**: ruído de entrada (desvio =  $1,0 \times$  amplitude do sinal) degrada apenas  $1,001\times$ ; morte de 40% dos neurônios em inferência degrada  $1,023\times$  (pior caso  $1,047\times$ , dentro da tolerância  $2,0\times$ ). O organismo tolera nós caindo — premissa da Fase 2 sustentada empiricamente.

**Benchmarks públicos (psMNIST permutado):**

| Modelo       | Acurácia (2k/60ep) | Params | Acurácia (60k/Colab T4) |
|--------------|--------------------|--------|-------------------------|
| CfC (h=64)   | 0,358              | 5.002  | 0,6939                  |
| LSTM (h=128) | 0,434              | 67.850 | 0,8149                  |
| GRU (h=128)  | 0,488              | 50.816 | não medido              |

Razão de parâmetros: LSTM/CfC = **13,56** $\times$ , GRU/CfC = **10,16** $\times$  (alegação “ $10\times$  menos” sustentada). No complemento 60k, o CfC fica 12,1 pp atrás do LSTM, porém com 13,56 $\times$  menos parâmetros. O critério de **sucesso** (“empatar ou superar”) não foi atingido; o critério de **falha** ( $>15\%$  em duas tarefas) não dispara (1 tarefa completa, gap  $12,1\% < 15\%$ ). **O treino do GRU em 60k foi interrompido por queda de sessão Colab — acurácia final não medida; não inventamos o número.** Suíte visao/ fechou em 181 testes verdes.

### 5.3. Fase 2.1 — Enxame local (FedAvg)

Nó local de dois processos via socket (visao/swarm/), FedAvg por rodadas. Dois nós (200 amostras, shards 100/100, lr=0,01, K=5, 20 rodadas) convergem para o **mesmo estado** que treino single-node (erro relativo  $< 5\%$ ). Arquitetura-agnóstico: o CfC pluga depois. P2P real (libp2p/Iroh + handshake R3) ficou para a tarefa 2.3.

### 5.4. Fase 3 — Auto-melhoria verificável

- **Arquivo de variantes** (archive.py): grafo pai→filho; podar por fitness baixo é **proibido por construção** (PruningForbidden) — os becos sem saída são mantidos.

- **Loop de mutação** (`mutate.py`): perturba  $\tau$ /plasticidade/código; guarda R3 detecta marcadores proibidos (governança, rede, chaves) e levanta `ForbiddenMutation`.
- **Sandbox de fitness** (`sandbox.py`): subprocesso isolado — sem persistência (dir temporário sempre removido), sem rede (sombra de módulos + scan estático), `RLIMIT_CPU/RLIMIT_AS` matam loop infinito/alocação. Backend trocável sem alterar o contrato.
- **Portão de transferência** (`transfer.py`): variante só é aceita se o ganho no conjunto de otimização se sustenta num conjunto **fora** dele; rejeita trapaça de benchmark (teste end-to-end com fitness medido no Sandbox).

## 5.5. Fase 6 — Cérebro autocontido

- **6.1** `save_brain/load_brain` round-trip: erro  $< 10^{-6}$  nos pesos e no rollout.
- **6.2** pacote único `.py` autocontido: pesos em base64 + import da arquitetura.
- **6.3** self-verify no load (R3): o bundle embute o hash selado de `containment.py`; adulteração a quente é capturada no load (`BoundaryBreached`). Ao concluir, o manifesto R3 foi **re-selado**. Suíte `visao/` (`tests+evolve+governance`): 124 testes verdes.

## 6. Rede Descentralizada e Retenção

Modelo quantitativo de recrutamento (`network/recruitment_model.py`, ancorado em Anderson arXiv:1903.01699): viral sem retenção estabiliza em **zero** nós; nicho fiel estabiliza em 1.250 (aprox. US\$ 4,94 M/ano em nuvem); o Folding@home perdeu 98,6% da capacidade em cinco anos. Dashboard de churn (`churn_dashboard.py`, SQLite) rastreia nós ativos em 7d, churn mensal e  $N^*$  observado vs previsto.

**Problema zero** (decisão do Juan, 08/ago/2026): **nowcasting** de precipitação em bacias urbanas de Fortaleza usando a rede FUNCEME (600+ postos desde 1974). Métrica pública definida **antes**: RMSE(mm) a 1/3/6h vs baseline de persistência; sucesso = ensemble CfC  $\geq 15\%$  melhor em split temporal. O guardião de prontidão (`readiness_check.py`) imprime **PROIBIDO RECRUTAR** enquanto o cliente instalável ( $< 5$  min) e a tarefa 5.2 estiverem pendentes — honrando seu propósito.

## 7. Discussão e Limitações

O sistema é um **subsistema** — memória contínua eficiente e protocolo de segurança — não uma arquitetura de inteligência geral. Limitações declaradas e **não maquiadas**:

- $n = 5$  sementes e 96 neurônios são insuficientes para inferência estatística robusta;
- no benchmark psMNIST 60k, o CfC perde do LSTM em acurácia (12,1 pp) — a vantagem é paramétrica ( $13,56\times$  menos), não de acurácia;
- o GRU em 60k **não foi medido** (queda de sessão); não há número fabricado;
- H3 (contenção populacional) e o recrutamento real (Fase 5) seguem não implantados — o guardião bloqueia recrutamento prematuro;
- restam pendentes: 6.4/6.5 (R1+R4 no bundle, 39+ testes), 2.2–2.6 (Byzantinos, prova de contribuição, admissão, churn, sharding de  $10^5$  neurônios) e os portões da Fase 3.

## 8. Conclusão

Redes líquidas com plasticidade local reduzem o esquecimento por construção, e a contenção deve preceder a capacidade de replicação — **e neste projeto precedeu de fato**. As Fases 1, 2.1, 3 e 6 foram executadas e medidas com suítes verdes, validando a ordem de construção como disciplina de engenharia, não apenas de intenção. O cérebro autocontido (Fase 6) carrega arquitetura, pesos e freios num único arquivo verificável, mantendo R3 embutido no ponto de entrada.

## 9. Referências

- Hasani, R. et al. Liquid Time-constant Networks. **Nature** **MI** 4, 992–1003 (2022).
- Lechner, M. et al. Neural Circuit Policies (arXiv:1803.08554).
- Douillard, A. et al. DiLoCo (arXiv:2311.08105, 2023).
- Whittington, J. & Bogacz, R. Predictive coding com plasticidade Hebbiana local. **Neural Comp.** 2017.
- Pan, A. et al. Open-weight models and self-replication (2024).
- Palisade Research. AI self-exfiltration (2026).

- RAND. Strengthening Emergency Preparedness for AI (RRA3847-1, 2025).
- Anderson, D. BOINC (arXiv:1903.01699).
- McCloskey, M. & Cohen, N. Catastrophic interference (1989).