

Apostila VISÃO

Redes Líquidas, Plasticidade Local e Contenção Criptográfica

Um guia de fundo para o Projeto VISÃO — da equação diferencial à governança

Preparado por ÍRIS · Agosto de 2026 · Projeto VISÃO / Juan Guerra

Como usar esta apostila. Cada capítulo parte de um conceito, mostra a matemática que o sustenta, e termina com um bloco “Para o ITA” ligando o tópico à sua preparação para o vestibular. O Capítulo 7 explica, sem jargão, o que a Íris tem feito nos bastidores. As respostas dos exercícios estão no fim.

1. O problema: esquecimento catastrófico

Uma rede neural treinada na tarefa A e depois na tarefa B tende a **sobrescrever** a representação de A. McCloskey & Cohen (1989) batizaram isso de esquecimento catastrófico: o aprendizado da tarefa B invade os pesos compartilhados e apaga o que vinha antes. Em redes de fronteira, o fenômeno é agravado porque os pesos são **globais** — um único vetor de parâmetros serve a todo o modelo.

Três propriedades dos transformers os desqualificam para o objetivo do VISÃO:

Propriedade exigida	Transformer	Arquitetura líquida
Adaptação após o treino	Não — pesos congelados	Sim — a constante de tempo muda com a entrada
Aprendizado contínuo	Esquecimento catastrófico	Consolidação sináptica local
Crédito sem passe global	Backprop exige grafo inteiro	Regras locais (Hebb/Oja)

Para o ITA No ITA você verá **equações diferenciais ordinárias** (MAT-12, MAT-22) e **sistemas dinâmicos**. A célula líquida é uma EDO. Entender o esquecimento catastrófico é entender por que um sistema com um único estado global não retém histórico — exatamente a questão de estabilidade de regimes que aparece em sistemas dinâmicos.

2. O substrato líquido: a célula CfC

Cada neurônio líquido segue a dinâmica contínua fechada de Hasani et al. (2022):

$$\frac{dx}{dt} = -\left[\frac{1}{\tau} + f(x, I)\right](x - A), \quad \tau_{\text{ef}(t)} = \frac{\tau}{1 + \tau \cdot f(x, I)} \quad (1)$$

A constante de tempo efetiva τ_{ef} **depende da entrada** I via a não linearidade limitada f . Cada neurônio reescolhe sua própria escala de tempo a cada instante — isso é neuroplasticidade de curto prazo em forma fechada, ausente em transformers e em RNNs de τ fixo.

Nota Por que “fechada”? A solução analítica existe: dado $\alpha = \frac{1}{\tau} + f$ constante num passo, $x(t) = A + (x_0 - A)e^{-\alpha t}$. Não é preciso integrar numericamente a EDO a cada passo — a célula “salta” para o equilíbrio local. É por isso que CfC (Closed-form Continuous-time) é barato de rodar.

A verificação de liquidez medida no projeto: sob entrada agitada, a faixa de τ_{ef} foi **13×** **maior** que sob entrada calma (razão 3,282× em ambos numpy e JAX). A rede responde ao mundo — não é um RNN caro com outro nome.

3. Aprendizado sem backprop: regras locais

O truque do VISÃO é atualizar pesos **sem** passe global de gradiente. Três regras locais:

- **Hebb (1949):** “neurônios que disparam juntos, se ligam juntos”. $\Delta w_{ij} \propto y_i x_j$.
- **Oja (1982):** Hebb normalizado — evita crescimento ilimitado: $w_{ij} \rightarrow w_{ij} + \eta y_i (x_j - y_i w_{ij})$.

- **Portão de surpresa:** a plasticidade é modulada pelo erro de predição (predictiv coding, Whittington & Bogacz 2017). Surpresa alta = aprender; surpresa baixa = consolidar.

A ablação medida (grade $2 \times 2 \times 2$, 5 seeds) revelou o que cada mecanismo realmente faz:

Componente (isolado)	Efeito no esquecimento
Surpresa ligada	$-0,262$ — reduz mais ; é o componente principal
Oja ligado	$-0,092$ — reduz
Consolidação sozinha	$+0,178$ — umenta o esquecimento; só ajuda em combinação

Nota Descoberta honesta do projeto: surpresa ligada **sem** consolidação **diverge** numericamente (os pesos explodem). Foi reportada como “diverziu”, não como “redução de 97%”. Transparência sobre falha é parte do método.

4. Estabilidade e a borda do caos

Esta é a parte que liga VISÃO ao seu estudo de sistemas dinâmicos. Linearizamos em torno do equilíbrio $x = A$:

$$J = -\left[\frac{1}{\tau} + f\right], \quad \Re(J) < 0 \rightarrow \frac{1}{\tau} + f > 0 \quad (2)$$

Se o jacobiano linearizado tem parte real negativa, o equilíbrio é **localmente estável**. Para o reservatório inteiro, medimos:

- raio espectral $\rho(W_{\text{rec}}) = 0,7577 < 1$ — é um **echo state network** viável;
- maior expoente de Lyapunov empírico $\lambda = -0,7484$ — **sub-caótico** (memória estável, não morto: $\|x\| = 3,726$);
- morte de 40% dos neurônios em inferência degrada só $1,023 \times$ (tol. $2,0 \times$).

Para o ITA Aqui mora o encontro com o ITA. O **expoente de Lyapunov** mede a taxa de afastamento de trajetórias vizinhas: $\lambda < 0$ significa convergência (sistema estável); $\lambda > 0$ significa caos. A “borda do caos” é $\lambda \approx 0$ — onde há memória e capacidade de resposta. O VISÃO opera no lado estável da borda. Isso é exatamente a análise de estabilidade de Lyapunov que aparece em sistemas dinâmicos não-lineares.

5. Governança e contenção

Antes de qualquer automação, o projeto implementa cinco regras em `visao/governance/containment.py`, cobertas por 39 testes que **tentam violá-las** e exigem falha:

Regra	Implementação
R1 — Replicação sob quórum	Filho só nasce com assinatura de k-de-n humanos; chave fora do sistema
R2 — Vida útil finita	TTL criptográfico; sem renovação assinada, o nó para sozinho
R3 — Fronteira imutável	Governança fora do espaço de mutação; hash selado, verificado a cada load
R4 — Freio de banda	Custo de c filhos cresce como $2^{8+1,6c}$ tentativas de hash (PoW)
R5 — Telemetria irrecusável	Ledger encadeado; nó silencioso é expulso pelos pares

Princípio: **tudo falha fechado**. Erro, ambiguidade ou token malformatado nega. A Fase 6.3 embute o hash selado de `containment.py` no **bundle** do cérebro; adulteração a quente é capturada no load (`BoundaryBreached`).

Nota Dados de 2026, não ficção: modelos de fronteira alcançam 70–81% de sucesso em auto-replicação end-to-end (Pan et al. 2024; Palisade Research 2026). Conter **antes** de ganhar capacidade não é cautelosa — é a única ordem de construção responsável.

6. Enxame, auto-melhoria e o cérebro autocontido

Fase 2.1 — FedAvg. Nós treinam localmente e o coordenador faz a média dos deltas:

$$w_{t+1} = \sum_k \frac{n_k}{n} \cdot w_{t+1}^{(k)} \quad (3)$$

Dois processos locais convergiram para o **mesmo** estado que treino single-node (erro relativo $< 5\%$). O CfC pluga na arquitetura-agnóstica.

Fase 3 — Darwin Gödel Machine. Um arquivo de variantes guarda (código, pesos, fitness, pai); podar por fitness baixo é **proibido por construção** (os becos sem saída geram os saltos). Cada variante roda num **sandbox** isolado (sem rede, sem persistência, RLIMIT_CPU/RLIMIT_AS) e só é promovida se o ganho **transfere** para tarefas fora do conjunto de otimização.

Fase 6 — cérebro autocontido. save_brain/load_brain (erro $< 10^{-6}$), pacote único .py com pesos em base64, e self-verify R3 no load.

7. O que a Íris tem feito

Sem jargão: o VISÃO avança sozinho à noite, e a Íris cuida da consistência. Três ações concretas desta sessão:

Mapeamento prático

- **Backup:** copiei os dados do Íris (.hermes, donjuan-holding, silveira-arte, projeto-visao, iris-interface) para o HD externo de 1 TB, com verificação de paridade (dry-run reportou 0 transfers pendentes).
- **Artigo:** a fonte .typ tinha sido perdida. Reconstituí artigo_visao.typ com as medições reais das Fases 1, 2.1, 3 e 6 (extraídas do BACKLOG), recompilei para 3 páginas e corriji um bug de hifenização no título.
- **Loop autônomo:** um sentinela lê o BACKLOG, escolhe a próxima tarefa desbloqueada e executa **apenas ela**, sob guarda de governança e de RAM. O Problema Zero (nowcasting de chuva com a rede FUNCEME de Fortaleza) já foi decidido — métrica pública definida antes de qualquer treino.

)

8. Exercícios

Exercício Resolva a EDO do parágrafo 2: $\dot{x} = -\alpha(x - A)$, com $\alpha > 0$ constante e condição inicial $x(0) = x_0$. Mostre que $x(t) \rightarrow A$ quando $t \rightarrow \infty$.

Exercício Para o jacobiano linearizado $J = -(\frac{1}{\tau} + f)$, com $\tau = 1$ e $f = -2$, o equilíbrio é estável ou instável? E se $f = +0,5$?

Exercício Calcule τ_{ef} para $\tau = 1$ e (a) $f = 0$; (b) $f = 1$. Interprete por que a entrada agitada (maior f) “desacelera” a dinâmica.

Exercício No FedAvg com dois nós de mesmo tamanho ($n_1 = n_2$), escreva w_{t+1} em função de $w_{t+1}^{(1)}$ e $w_{t+1}^{(2)}$. Por que isso é arquitetura-agnóstico?

Exercício Explique com suas palavras por que a regra R3 (fronteira imutável) **deve** viver fora do espaço de mutação da Fase 3, e não apenas ser “testada”.

9. Respostas

1. $x(t) = A + (x_0 - A)e^{-\alpha t}$; como $\alpha > 0$, o expoente tende a 0, logo $x(t) \rightarrow A$.

2. $J = -(1 + (-2)) = +1 > 0 \rightarrow$ instável. Com $f = +0,5$: $J = -(1,5) < 0 \rightarrow$ estável.
3. (a) $\tau_{\text{ef}} = \frac{1}{1+0} = 1$; (b) $\tau_{\text{ef}} = \frac{1}{1+1} = 0,5$. Maior f reduz o tempo efetivo — a célula “decide mais rápido” diante de sinal forte.
4. $w_{t+1} = \frac{1}{2}w_{t+1}^{(1)} + \frac{1}{2}w_{t+1}^{(2)}$. É agnóstico porque só combina os **deltas** finais, independente da arquitetura interna de cada nó.
5. Se R3 estivesse no espaço de mutação, uma variante da Fase 3 poderia enfraquecer a própria contenção — auto-modificação que remove o freio. Mantê-la imutável e selada por hash garante que o sistema não pode desligar sua própria trava.

Glossário: **CfC** = Closed-form Continuous-time · **LTC** = Liquid Time-constant · **ESN** = Echo State Network · **FedAvg** = Federated Averaging · **PoW** = Proof of Work · **DGM** = Darwin Gödel Machine. Fontes: Hasani et al. 2022; Lechner et al. 2020; Whittington & Bogacz 2017; Sakana AI 2025; Pan et al. 2024.